ДОМАШНЕЕ ЗАДАНИЕ № 1

Параллельное умножение матриц (DGEMM)

Графики и краткий анализ масштабируемости

Выполнил: _____ Группа: _____

1. Условия эксперимента

Измерения получены на суперкомпьютере «Харизма» в рамках единого задания SLURM № 4392460 на вычислительном узле cn-036. Использовались процессоры Intel Xeon Gold 6248R (3,00 ГГц); узел содержит два сокета по 24 ядра. Для эксперимента выделено 24 CPU.

Тип данных и хранение	double; одномерные массивы; column-major
Размеры матриц	N = 500, 1000, 1500
Число потоков	P = 1, 2, 4, 8, 16, 24
Статистика времени	Среднее по 10 повторным умножениям
Сравниваемые реализации	Собственный OpenMP DGEMM, OpenBLAS, Intel MKL
Сборка	C++11, GCC, оптимизация -O3, OpenMP

2. Методика вычислений

Матрицы A, B и C имеют размер N × N. Собственная реализация параллелизует внешний цикл по столбцам результирующей матрицы с помощью OpenMP schedule(static). Каждый поток записывает только в выделенные ему столбцы C.

Число арифметических операций оценивается как $2N^3$; производительность вычисляется как $GFLOPS = 2N^3 / (T \times 10^9)$, где T — среднее время умножения в секундах.

Правильность собственной параллельной реализации проверена сравнением с последовательным результатом. В финальном запуске все 18 проверок для сильной масштабируемости дали «CHECK: OK», максимальная абсолютная разность была равна нулю. Библиотечные результаты также сравнивались с результатом собственного DGEMM; выполнение завершилось без сообщения о нарушении допуска.

Примечание к измерениям: время собственного DGEMM отсчитывается внутри параллельной области после её создания, а для библиотек — вокруг вызова cblas_dgemm(). Это различие следует учитывать при строгом количественном сравнении.

3. Сильная масштабируемость

Размер N фиксирован, число потоков P увеличивается. Ниже показано влияние числа потоков на время и производительность.

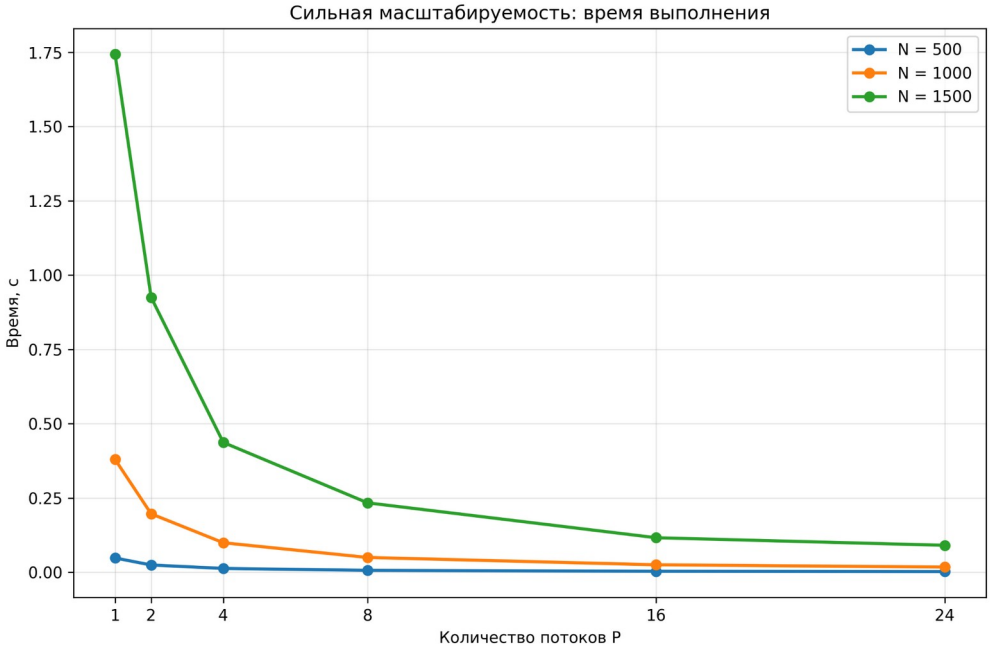


Рисунок 1 — Время выполнения DGEMM при фиксированном N (сильная масштабируемость).

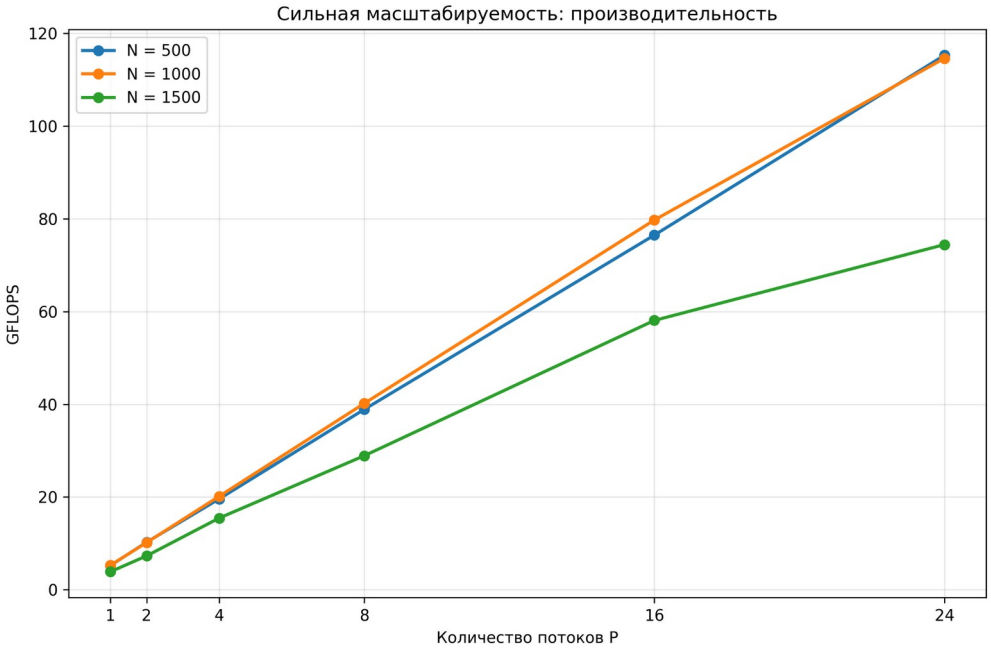


Рисунок 2 — Производительность DGEMM при фиксированном N (сильная масштабируемость).

С увеличением P время вычислений уменьшается, а GFLOPS растёт для всех N. Например, для N = 1000 время собственной параллельной реализации сократилось с 0,380 с при P = 1 до 0,017 с при P = 24 (примерно в 21,8 раза). При N = 1500 ускорение менее равномерное: рост числа потоков не компенсирует все ограничения вычислений и обмена данными.

4. Слабая масштабируемость

При слабой масштабируемости размер задачи растёт по формуле $N(P) = \text{round}(N_0 \times \sqrt[3]{P})$. Это сохраняет приблизительно постоянное число арифметических операций на один поток.

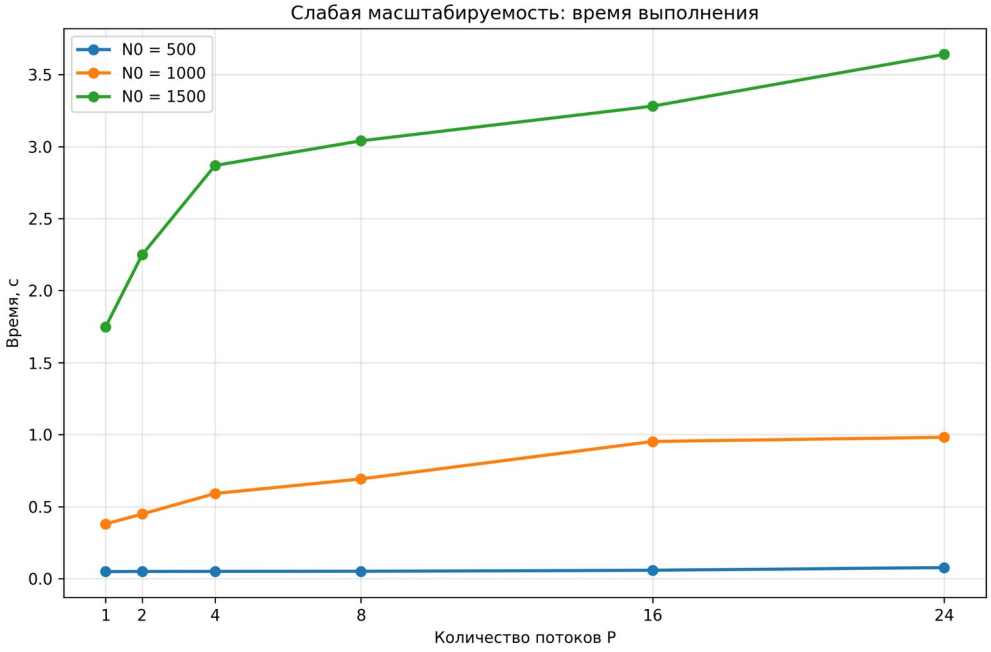


Рисунок 3 — Время выполнения при увеличении размера задачи (слабая масштабируемость).

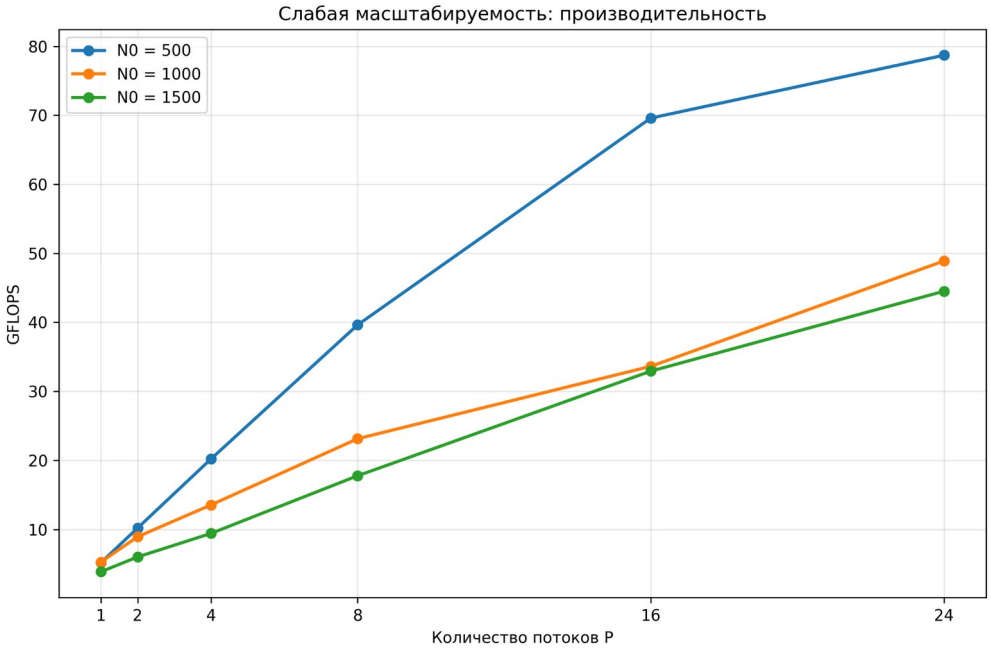


Рисунок 4 — Производительность при увеличении размера задачи (слабая масштабируемость).

Для $N_0 = 500$ время изменяется относительно слабо; при $N_0 = 1000$ и 1500 оно возрастает заметнее. Значит, идеальная слабая масштабируемость не достигнута. Возможные причины — увеличение рабочего объёма данных, влияние кэша и памяти, а также накладные расходы параллельного исполнения. При этом суммарные GFLOPS повышаются с ростом P.

5. Сравнение с библиотеками: N = 500

Сопоставляются собственный OpenMP DGEMM, многопоточная OpenBLAS и Intel MKL при одинаковых размерах матриц и количестве потоков.

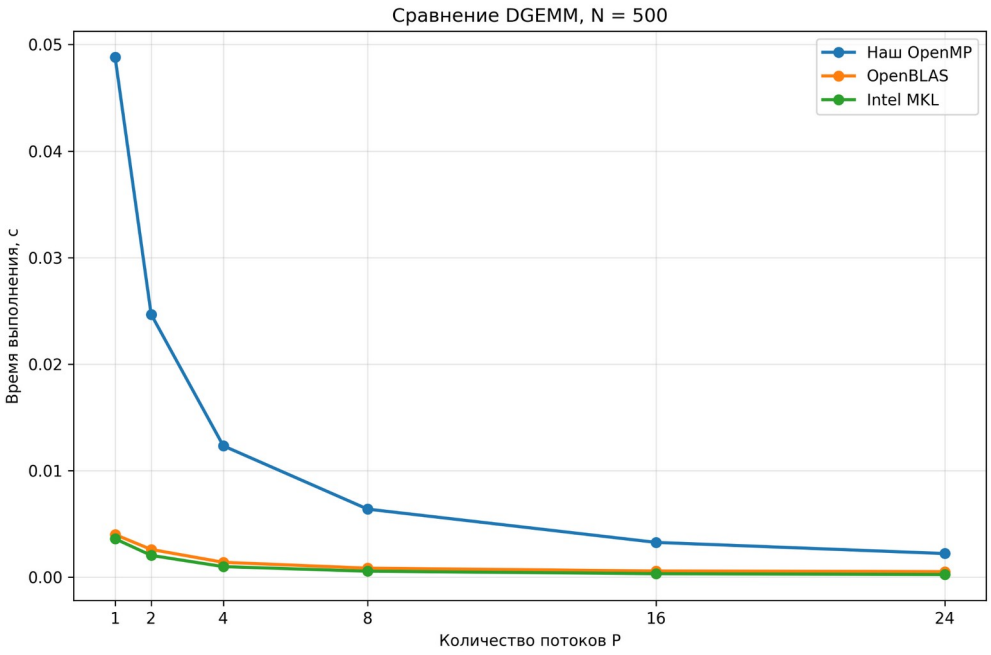


Рисунок 5 — Время выполнения DGEMM, N = 500: OpenMP, OpenBLAS и MKL.

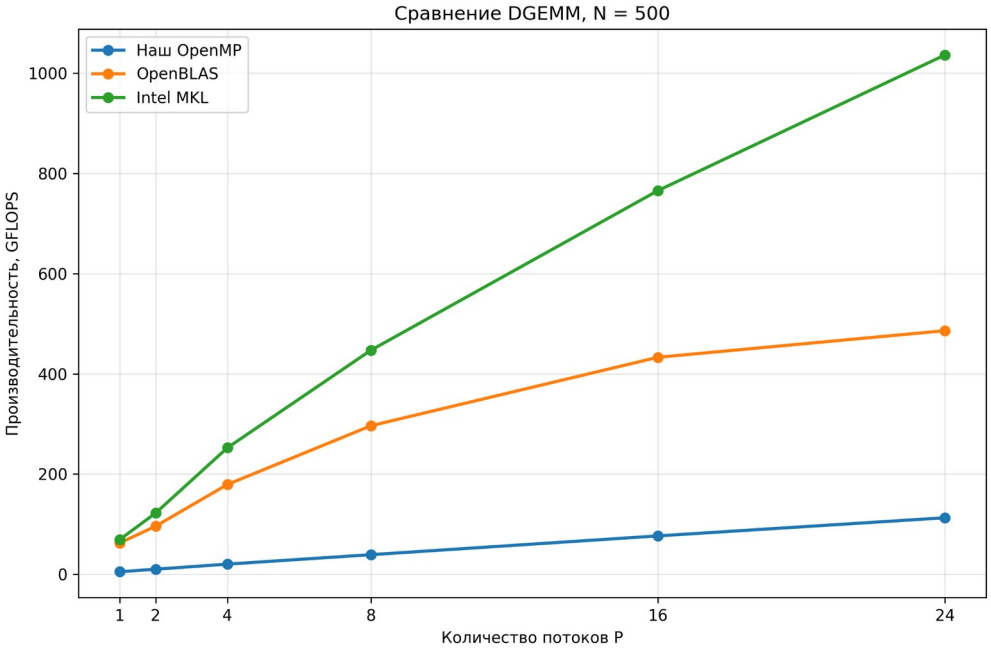


Рисунок 6 — Производительность DGEMM, N = 500: OpenMP, OpenBLAS и MKL.

Обе библиотеки выполняют умножение существенно быстрее собственной реализации. Intel MKL показывает максимальную производительность; OpenBLAS занимает промежуточное положение. С ростом P улучшаются все три реализации, но преимущество оптимизированных библиотек сохраняется.

6. Сравнение с библиотеками: N = 1000

Сравнение проводится для шести значений числа потоков от 1 до 24; скорость рассчитывается по одному и тому же объёму операций $2N^3$.

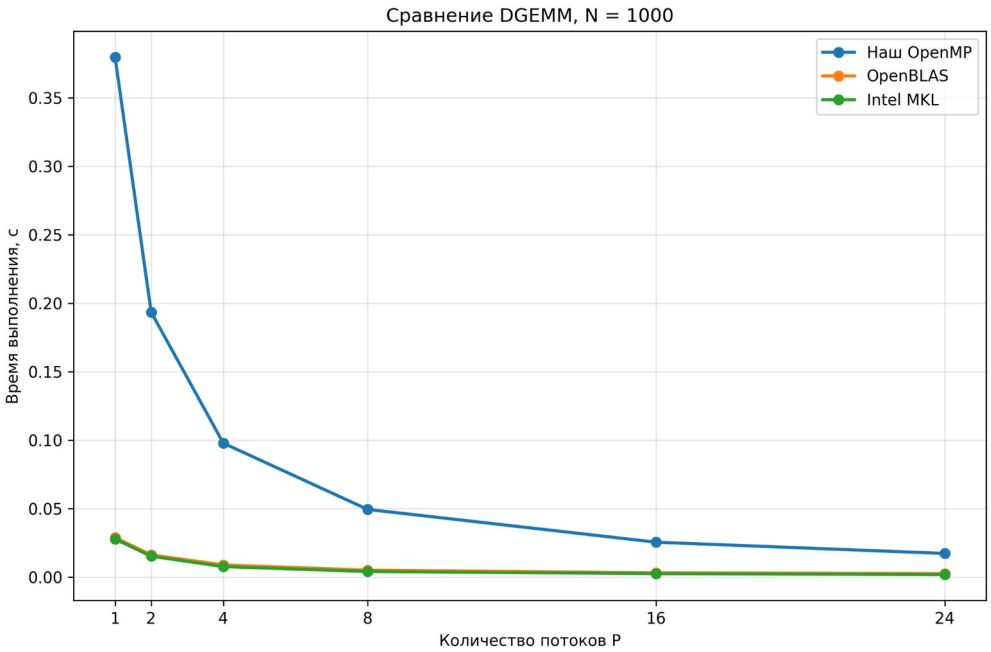


Рисунок 7 — Время выполнения DGEMM, N = 1000: OpenMP, OpenBLAS и MKL.

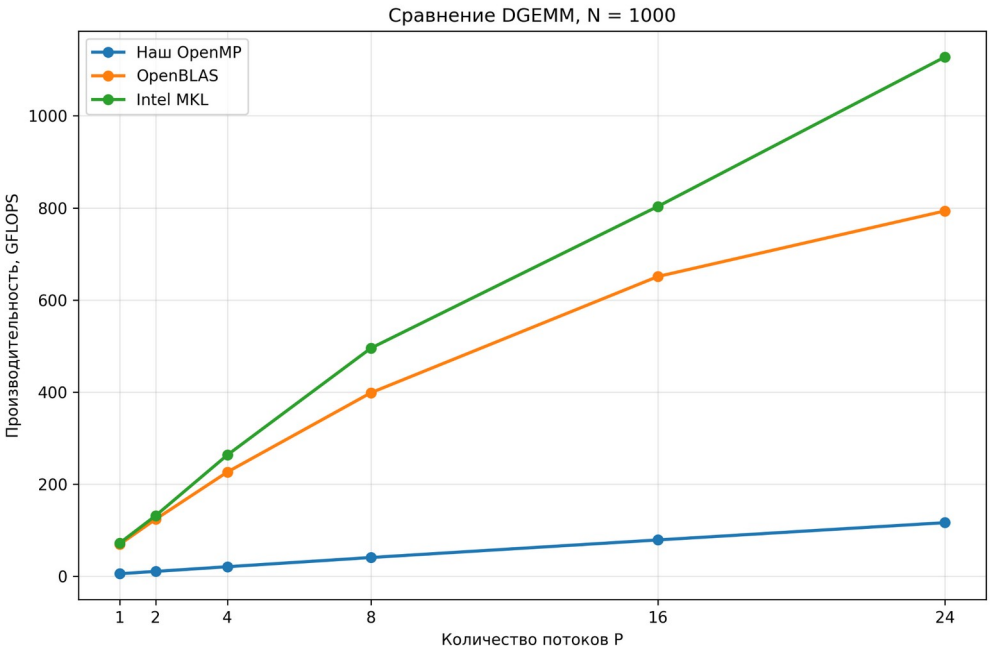


Рисунок 8 — Производительность DGEMM, N = 1000: OpenMP, OpenBLAS и MKL.

При N = 1000 производительность растёт с количеством потоков у всех трёх реализаций. Наибольших GFLOPS достигает MKL, затем OpenBLAS; собственный DGEMM медленнее. Разрыв объясняется более эффективными вычислительными ядрами и использованием памяти в специализированных BLAS-библиотеках.

7. Сравнение с библиотеками: N = 1500

Наибольший рассматриваемый размер матрицы позволяет оценить поведение реализаций при возросшей вычислительной нагрузке.

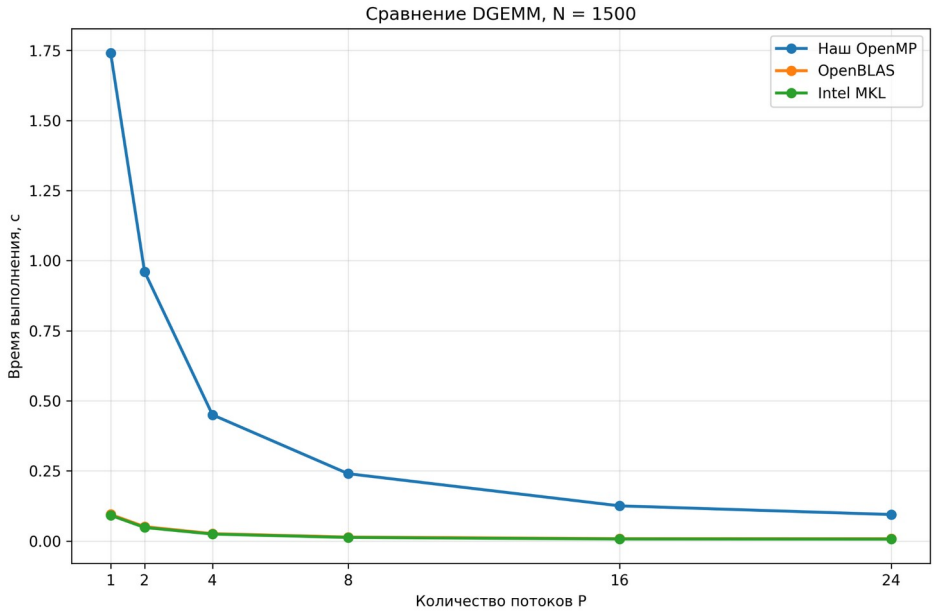


Рисунок 9 — Время выполнения DGEMM, N = 1500: OpenMP, OpenBLAS и MKL.

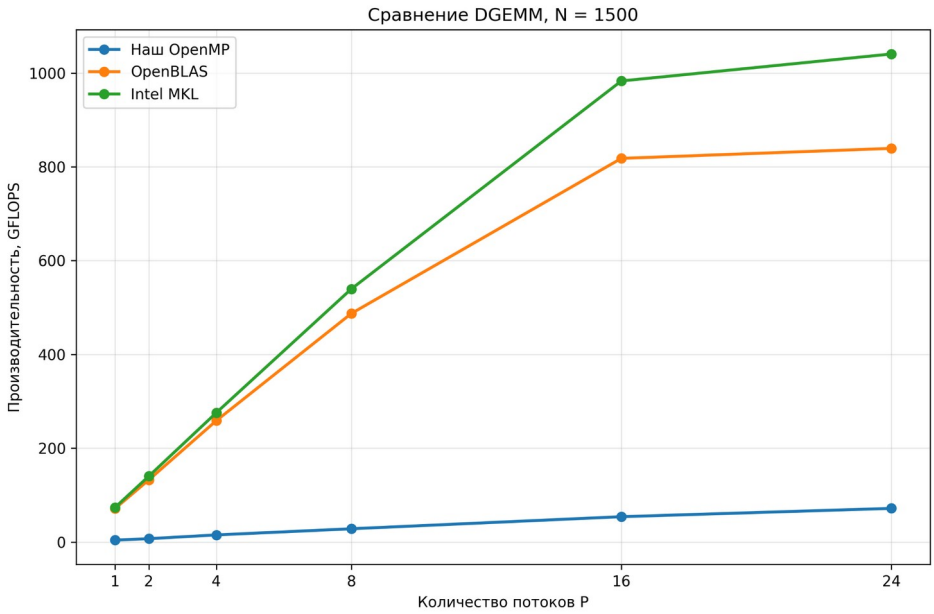


Рисунок 10 — Производительность DGEMM, N = 1500: OpenMP, OpenBLAS и MKL.

На матрицах N = 1500 преимущество BLAS-библиотек сохраняется. При переходе от 16 к 24 потокам прирост производительности обеих библиотек уменьшается: дальнейшее масштабирование ограничивают архитектурные ресурсы процессора и организация вычислений.

8. Общий вывод

Собственная OpenMP-реализация DGEMM корректна и ускоряется с ростом числа потоков. В слабой масштабируемости постоянное время поддерживается лишь приблизительно. OpenBLAS и особенно Intel MKL обеспечивают более высокую производительность благодаря специализированным оптимизациям. Все десять графиков построены по единому финальному запуску на узле cn-036.